Trabalho Prático 1

Estudante: Sarah Menks Sperber
Matrícula: 2023001824

Introdução:

Este trabalho consiste em melhorar a infraestrutura de dados de um arquivo com um grande número de informações. Para resolver esse problema, serão implementados três algoritmos diferentes: Quick Sort (com média de 3), Insertion Sort e Selection Sort, que farão o trabalho de ordenar o arquivo. Assim, no decorrer deste relatório, vamos fazer uma análise profunda desses algoritmos, discutindo pontos como metodologias usadas, uso de memória e complexidade assintótica.

Métodos:

O código usado é, em tese, bem simples. Foram usados dois TADs, Pessoa.hpp e Ordenacao.hpp, que guardam as declarações de todas as funções do código.
Os arquivos Pessoa.cpp e Ordenacao.cpp apenas implementam as funções, que serão discutidas posteriormente.
Por fim, a main.cpp é aquela que executa o código, já que é ela que abre o arquivo e chama as funções.

1. Pessoa.hpp:
O TAD Pessoa.hpp é responsável por criar a struct Pessoa, que armazena o nome, cpf, endereço e as outras informações de uma das linhas do arquivo. Esse TAD também contém uma função que imprime essas informações da Pessoa.

2. Ordenacao.hpp:
Cria a struct Ordenação, que declara um vetor de Pessoas, um vetor de índices (usado para ordenação indireta), os algoritmos de ordenação e funções auxiliares, uma que retorna o tipo de chave a ser ordenada (nome, cpf ou endereço) e outra que imprime o arquivo.
As funções principais realizam as declarações do construtor (que cria e aloca o vetor de “Pessoa”) e as declarações dos algoritmos de ordenação (Quick Sort, Insertion Sort e Selection Sort).
As funções auxiliares consistem, basicamente, em imprimir a saída da ordenação e criar o vetor de Pessoas. As impressões incluem tanto a primeira parte do arquivo, com as informações de formatação (chamadas de cabeçalho) quanto as próprias linhas do arquivo. As outras funções escolhem o atributo a ser ordenado e retornam a string a ser comparada (para auxiliar na ordenação indireta), além de criar o vetor de pessoas.

3. Main.cpp:
Recebe o arquivo a ser ordenado por parâmetro, declara um objeto do tipo “Ordenacao” e chama as funções Insertion Sort, Quick Sort e Selection Sort. Além disso, para um código mais seguro, a main.cpp possui boa parte das estratégias de robustez (como as checagens de parâmetro).

Análise de Complexidade:

Como dito anteriormente, foram implementados três algoritmos de ordenação, Quick sort, Insertion sort e Selection sort. Os casos de teste se deram por arquivos (não ordenados) de diversos tamanhos, em um intervalo de 10 a 5.000 linhas.
Vale destacar também o uso do vetor de índices mencionado anteriormente, que não é necessário para a execução dos algoritmos, mas que também depende do tamanho da entrada. Assim, esse vetor de índices adiciona O(n) na complexidade espacial do código.

1. Quick Sort:
O pior caso do quicksort é quando a divisão do vetor é mal balanceada, o que torna sua complexidade assintótica quadrática. Por causa disso, foi implementada a versão do quicksort que escolhe o pivô com uma média de 3 valores da lista, o que otimiza o algoritmo. Além disso, esse algoritmo não depende de um vetor auxiliar, porém, ele utiliza o vetor de índices declarado dentro do objeto "Ordenacao", o que piora sua complexidade espacial.
Complexidade assintótica no pior caso: $O(n^2)$. Complexidade espacial: O(n) (com o vetor de índices).

2. Insertion Sort:
O insertion sort é muito eficiente para valores pequenos, já que assim ele realizará poucas comparações. Seu melhor caso é quando o vetor já está ordenado, apresentando uma complexidade linear. Entretanto, quando o vetor está inversamente ordenado, o algoritmo apresenta um tempo quadrático (que é seu pior caso).
Complexidade assintótica: $O(n^2)$. Complexidade espacial: O(n) (com o vetor de índices).

3. Selection Sort:
A complexidade do Selection sort não muda de acordo com a entrada do arquivo, ou seja, ele sempre será quadrático (o que faz dele um algoritmo mais lento). Sua implementação é simples, se baseando em encontrar o menor elemento do vetor e colocá-lo na primeira posição. Por não depender do tamanho da entrada, o Selection obteve o pior desempenho, ponto que discutiremos mais abaixo.
Complexidade assintótica: $O(n^2)$. Complexidade espacial: O(n) (com o vetor de índices).

4. Outras funções:
Como foi dito anteriormente, as outras funções auxiliam os algoritmos de ordenação. Suas implementações são mais simples e mais diretas, e por isso suas análises de complexidade são mais triviais.

CriaPessoas: O(n)
- Percorre todo o arquivo

ImprimeCabecalho: O(k)
- (onde k é o tamanho do cabeçalho)

ImprimeArquivo: O(n)
- Percorre todo o vetor de Pessoas

ResetIndices: O(n)
- Percorre todo o vetor de índices

EscolheAtributo: O(1)

RetornaChave: O(1)

Estratégias de Robustez:

Para garantir um código seguro e sem falhas, algumas estratégias de segurança foram implementadas, tais como:

1. Função parse_args que checa os parâmetros:
Para evitar problemas com entradas inválidas, uma função de checagem dos parâmetros foi adicionada no arquivo main.cpp. Nela, nós checamos a quantidade de parâmetros passados para o programa, e caso o usuário não tenha colocado a quantidade de parâmetros adequada, o código não funcionará.

2. Verificação de arquivo válido:
Assim como a função parse_args checa os parâmetros, a função main possui um teste de checagem do arquivo. Se o usuário não passar a entrada desejada por parâmetro (um arquivo válido), o código é encerrado e uma mensagem de texto é exibida.

3. Verificação de atributo escolhido:
Além das funções mencionadas acima, o código confere o atributo a ser ordenado. Caso a pessoa não escolha um dos três atributos a serem ordenados (nome, CPF e endereço), o programa exibe uma mensagem de erro e é encerrado.

Análise Experimental:

1. Tempo:
Para a análise temporal, usei a biblioteca chromo para medir o tempo de execução de cada algoritmo e, assim, montar os gráficos.
Como esperado, o Quicksort obteve o melhor desempenho nos casos de teste, com seu tempo total chegando à casa dos $3*10^6$ nanossegundos. Já o Insertion teve um tempo de execução pior que o Quick Sort, chegando aos $2*10^8$ nanossegundos. Por fim, o Selection de longe obteve o pior desempenho, \alcançando a marca dos $5*10^8$ nanossegundos.

Gráfico com tempo de execução Quick Sort:

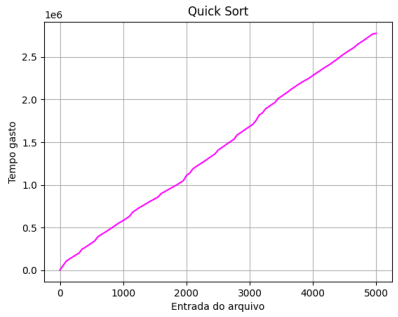

Gráfico com tempo de execução Insertion Sort:

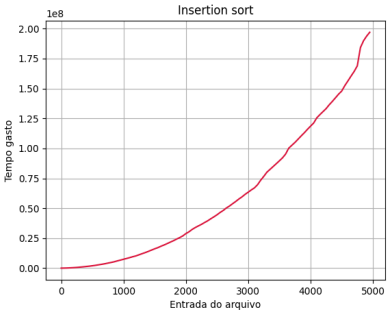

Gráfico com tempo de execução Selection Sort:

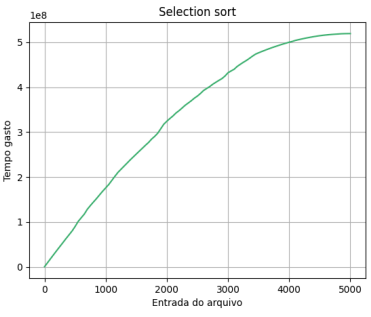

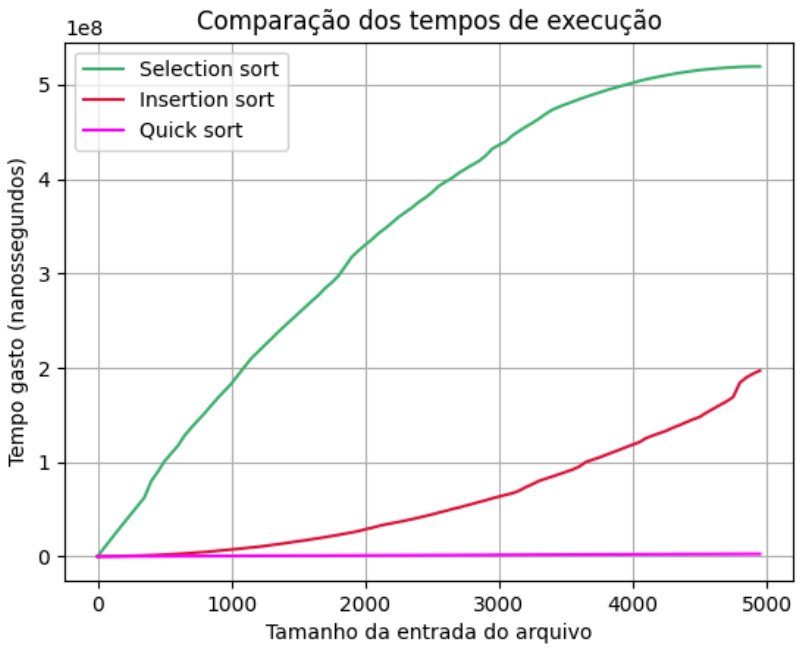

2. Localidade de referência:

No gráfico abaixo, vemos a dispersão do uso de memória para a impressão do arquivo, que não é tão eficiente, já que ele acessa posições aleatórias na memória.

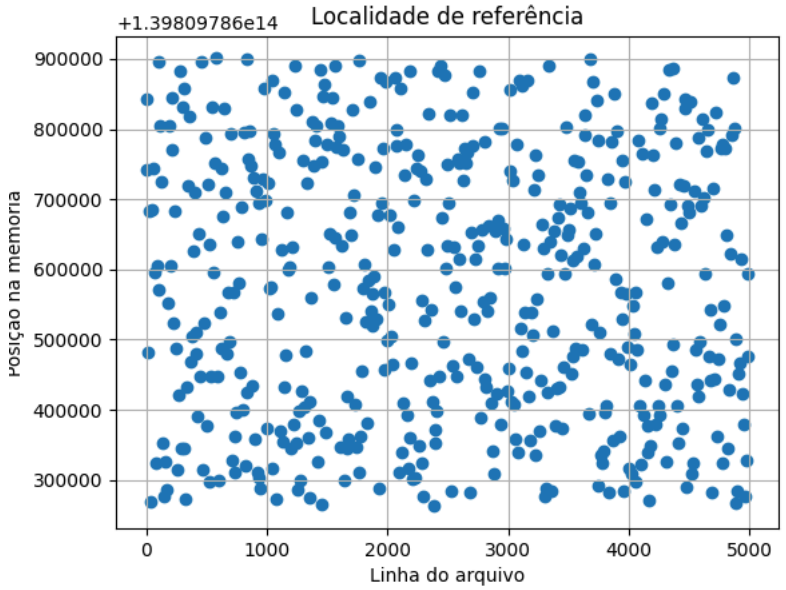

3. Distância de Pilha

Através do valgrind, podemos olhar a forma como o código usa o heap. Os algoritmos foram testados dentro do mesmo caso, começando pelo Insertion, seguido pelo quicksort e terminando com o selection sort. Ao analisar um arquivo menor, sem levar em consideração o uso de stack, o código apresentou um comportamento bem equilibrado, com seu ponto de maior uso localizado no meio da execução.

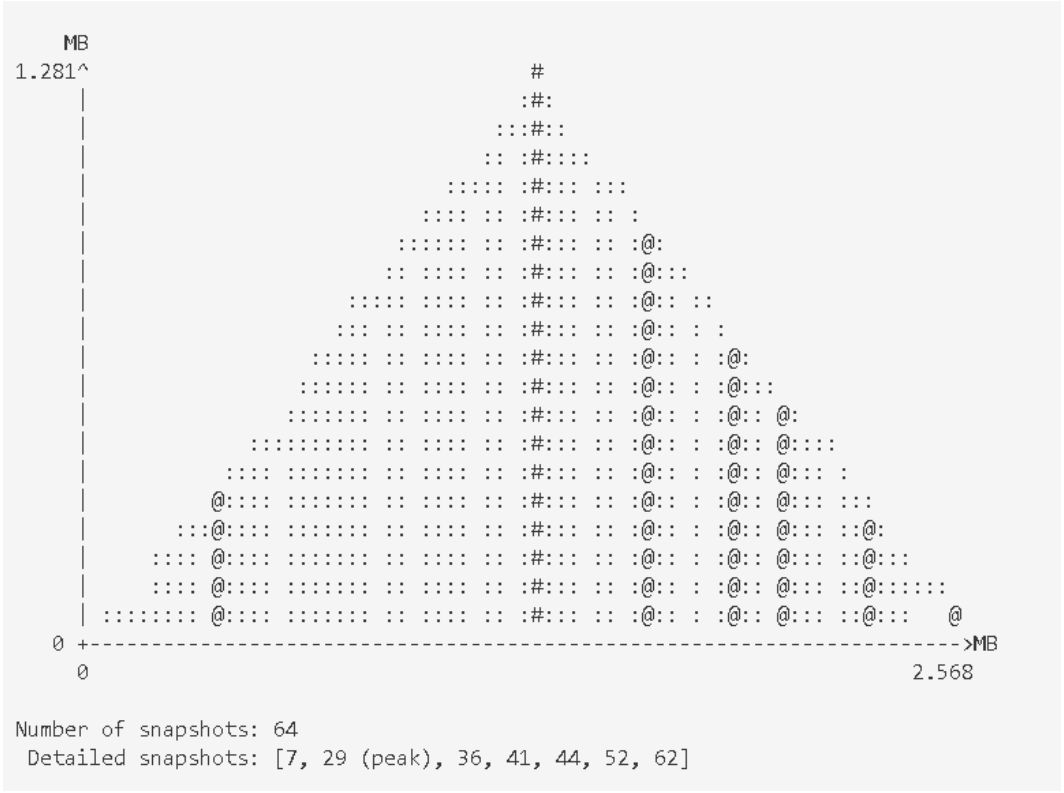


```
Number of snapshots: 64
 Detailed snapshots: [7, 29 (peak), 36, 41, 44, 52, 62]
```

n	time(B)	total(B)	useful-heap(B)	extra-heap(B)
8	425,304	419,112	412,236	6,876
9	471,320	465,128	456,782	8,346
10	502,888	496,696	487,305	9,391
11	540,064	533,872	523,196	10,676
12	602,040	595,848	583,124	12,724
13	651,440	645,248	630,915	14,333
14	680,688	674,496	659,197	15,299
15	724,672	718,480	701,717	16,763
16	780,960	774,768	756,136	18,632
17	820,416	814,224	794,200	20,024
18	851,944	845,752	824,695	21,057
19	899,264	893,072	870,399	22,673
20	939,680	933,488	909,463	24,025
21	971,200	965,008	939,945	25,063
22	1,018,544	1,012,352	985,703	26,649
23	1,050,144	1,043,952	1,016,244	27,708
24	1,097,424	1,091,232	1,061,972	29,260
25	1,142,352	1,136,160	1,105,382	30,778
26	1,198,752	1,192,560	1,159,847	32,713
27	1,266,304	1,260,112	1,225,129	34,983
28	1,311,280	1,305,088	1,268,611	36,477
29	1,349,488	1,343,296	1,305,591	37,705

Legenda tabela:
n: número da linha;
time(B): Tempo, medido em bytes;
Total(B): Quantidade de memória usada naquele ponto;
Useful-heap(B): Bytes alocados no heap, que são necessários para o programa;
Extra-heap(B): Memória extra alocada, como um processo auxiliar;

Já para arquivos maiores, analisando também o uso de stack, o código obteve uma grande mudança no comportamento. Agora, seu maior uso de heap foi na parte final da execução, que é onde se encontra o Selection sort, algoritmo mais custoso deste trabalho.

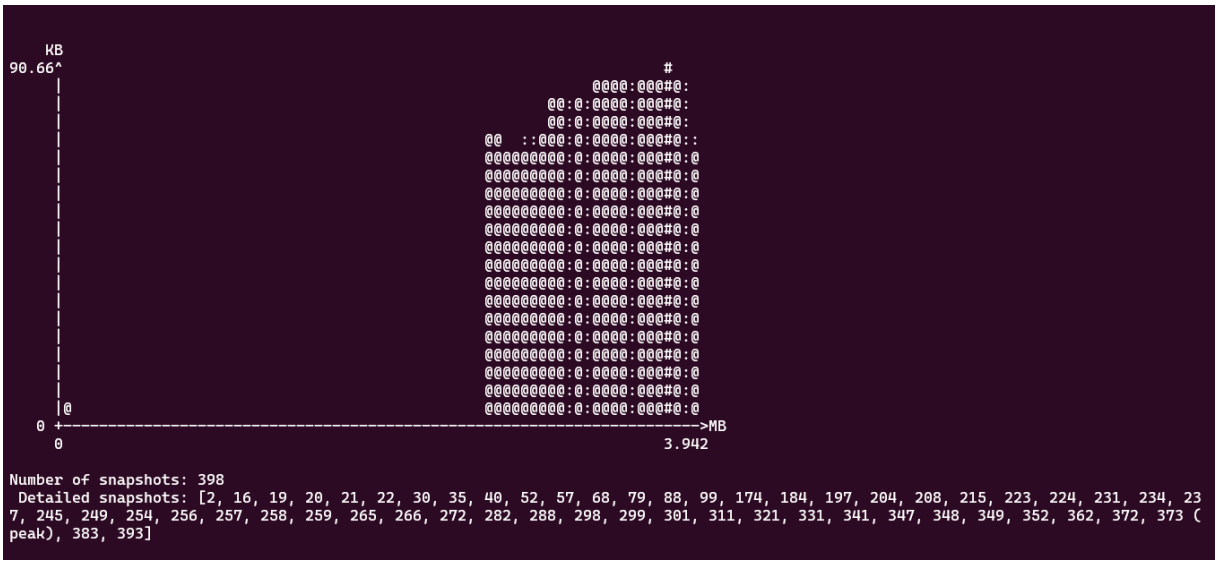


```
Number of snapshots: 398
 Detailed snapshots: [2, 16, 19, 20, 21, 22, 30, 35, 40, 52, 57, 68, 79, 88, 99, 174, 184, 197, 204, 208, 215, 223, 224, 231, 234, 23
7, 245, 249, 254, 256, 257, 258, 259, 265, 266, 272, 282, 288, 298, 299, 301, 311, 321, 331, 341, 347, 348, 349, 352, 362, 372, 373 (
peak), 383, 393]
```

n	time(B)	total(B)	useful-heap(B)	extra-heap(B)	stacks(B)
373	3,885,800	92,840	91,139	261	1,440

Legenda tabela:
n: número da linha;
time(B): Tempo, medido em bytes;
Total(B): Quantidade de memória usada naquele ponto;
Useful-heap(B): Bytes alocados no heap, que são necessários para o programa;
Extra-heap(B): Memória extra alocada, como um processo auxiliar;
Stacks(B): Uso de stack

Conclusão:

Após analisar detalhadamente o código feito, concluímos que os diferentes algoritmos de ordenação possuem desempenhos diferentes, mesmo com complexidade assintótica semelhantes no pior caso. Neste trabalho, aprendi a medir e comparar os diferentes tempos de execução dos algoritmos, aprendi também a avaliar a localidade de referência e a distância de pilha do código, além de conhecer os algoritmos de ordenação mais profundamente.

Bibliografia:

MATPLOTLIB. *Matplotlib 3.0.0 documentation*. Disponível em: https://matplotlib.org/stable/. Acesso em: 2 dez. 2024.

C++ REFERENCE. *chrono - C++ Reference*. Disponível em: https://cplusplus.com/reference/chrono/. Acesso em: 2 dez. 2024.

VALGRIND. *Valgrind User Manual*. Disponível em: https://valgrind.org/docs/manual/ms-manual.html. Acesso em: 2 dez. 2024.